

Detección de melanomas mediante segmentación automática y aprendizaje supervisado

Dora Lucía Díaz Galindo
Máster en Bioinformática para Ciencias de la Salud
Universidad de Coruña
A Coruña, España
dora.diaz@udc.es

Abstract—El melanoma representa la variante más agresiva de los tumores cutáneos, por lo que su diagnóstico en estadios iniciales resulta crítico para la supervivencia del paciente. En este trabajo se propone una metodología automática en dos etapas para la identificación de melanomas a partir de imágenes de lesiones dermatológicas. La primera etapa consiste en la segmentación de la lesión sobre el canal azul de la imagen, combinando técnicas como *black-hat* e *inpainting* para eliminar artefactos, seguido de umbralización de Otsu y limpieza morfológica. Seguidamente se realiza una validación de la segmentación utilizando la métrica IoU. Por otra parte, la segunda etapa extrae, sobre la región segmentada, cinco descriptores basados en la regla clínica ABCDE (asimetría, circularidad, media y desviación típica del canal rojo, y contraste GLCM), para clasificar los lunares con una SVM de kernel lineal, cuyo parámetro de penalización C se optimiza automáticamente. Por último, la validación se realiza con *Leave-One-Out Cross-Validation* (LOOCV). Los resultados obtenidos son un IoU medio del 82,83% en segmentación y un acierto del 90,20% en clasificación, con 84,21% de sensibilidad y 93,75% de especificidad.

Index Terms—melanoma, dermatoscopia, segmentación, ABCDE, GLCM, SVM, LOOCV, ISIC.

I. INTRODUCCIÓN

El melanoma maligno es el tipo de cáncer de piel más agresivo y el responsable de la mayor tasa de mortalidad asociada a tumores cutáneos. Su pronóstico clínico depende críticamente de una detección temprana: cuando se diagnostica y trata en estadios iniciales (enfermedad localizada), la supervivencia relativa a cinco años supera el 99%, mientras que en fases metastásicas a distancia esta probabilidad se reduce drásticamente hasta el 35% [1]. En este contexto, aunque la dermatoscopia ha mejorado notablemente la inspección visual, los sistemas de diagnóstico asistido por ordenador (CAD) mediante visión artificial resultan clave para apoyar al especialista y aportar mayor objetividad al análisis clínico [2].

Para el desarrollo de este trabajo se ha utilizado un conjunto de 51 imágenes dermatoscópicas proveniente de un reto de segmentación y clasificación de lesiones dermatológicas organizado en 2018 por la *International Skin Imaging Collaboration* (ISIC), compuesto por 19 imágenes de melanomas y 32 de lunares benignos. Cada imagen va acompañada de su máscara de segmentación manual (*Ground Truth*) y de un fichero *list.csv* con el etiquetado binario (0 = benigno, 1 = melanoma).

El flujo de trabajo se divide en dos fases:

- 1) **Segmentación:** desarrollo de un algoritmo de segmentación automática que extraiga la región de la lesión y la posterior validación estadística del resultado frente a las máscaras manuales del experto.
- 2) **Clasificación:** extracción de descriptores que cuantifiquen la lesión y entrenamiento de un clasificador supervisado mediante validación cruzada para distinguir lunares benignos de melanomas.

El resto del documento se organiza de la siguiente manera: la Sección II detalla la metodología propuesta; la Sección III expone los resultados obtenidos en ambas fases; y, finalmente, la Sección IV presenta las conclusiones del trabajo.

II. PROPUESTA TÉCNICA

En esta sección se describen los métodos y algoritmos utilizados para construir el sistema de detección. Los apartados A y B corresponden a la primera fase descrita (segmentación), mientras que los apartados posteriores detallan la segunda fase (clasificación).

A. Procesamiento y Segmentación

La segmentación de la lesión se lleva a cabo en un proceso secuencial de cinco pasos:

- 1) **Selección del canal azul.** Se opera únicamente sobre el canal B del espacio RGB. La melanina absorbe una gran cantidad de radiación en esta banda de longitud de onda corta, lo que oscurece significativamente la lesión y maximiza su contraste morfológico frente a la piel sana.
- 2) **Eliminación de vello.** Se aplica una transformación morfológica *black-hat* utilizando un kernel rectangular de 17×17 píxeles. Esta operación permite aislar estructuras que son más oscuras que su entorno y cuyo grosor es inferior al tamaño del kernel (como el vello capilar). El resultado se binariza aplicando un umbral de valor 10 para filtrar el ruido base de la piel sana y conservar únicamente la estructura del vello. Finalmente, mediante el algoritmo de *inpainting* de Telea, se eliminan estos pelos rellenando sus píxeles con el color y la textura de los píxeles que están justo al lado, logrando que la imagen quede limpia y continua.

- 3) **Suavizado.** Se aplica un filtro de mediana de tamaño 9, que elimina ruido residual preservando los bordes de la lesión.
- 4) **Umbralización Otsu.** Sobre la imagen limpia se aplica una umbralización binaria invertida con método de Otsu, que selecciona automáticamente el umbral óptimo entre las distribuciones de piel y lesión. Se utiliza la variante invertida para que los píxeles oscuros de la lesión adquieran el valor máximo (255, blanco) y el fondo claro pase a ser nulo (0, negro), generando así la máscara base de la región de interés.
- 5) **Limpieza de artefactos y post-procesado.** Una vez obtenida la máscara binaria, se lleva a cabo la limpieza final. Primero, se eliminan las franjas oscuras habituales en los bordes de la imagen mediante un análisis de densidad de píxeles: si la intensidad media en los márgenes supera un umbral de 200, la región se identifica como artefacto y se descarta. A continuación se aplica un cierre morfológico (kernel elíptico 20×20) para unir fragmentos cercanos de la lesión que hayan quedado desconectados y, finalmente, se extrae el contorno externo de mayor área y se rellena para generar la máscara sólida definitiva.

B. Validación de la segmentación mediante IoU

Las máscaras generadas (S) se comparan con la *Ground Truth* (GT) anotada por el experto. Como métrica principal se emplea el índice de Jaccard o *Intersection over Union* (IoU):

$$IoU = \frac{|S \cap GT|}{|S \cup GT|} \quad (1)$$

El IoU toma valores entre 0 y 1: un valor de 1 indica solapamiento perfecto y 0 indica que no hay coincidencia. La métrica se obtiene tanto por imagen como de forma global mediante el IoU medio (mIoU).

Complementariamente, para cada imagen se cuantifican los falsos positivos (FP, píxeles segmentados por el algoritmo pero ausentes en el GT) y los falsos negativos (FN, píxeles del GT no recuperados). Esto permite identificar visualmente las regiones donde el algoritmo sobreestima o infraestima la lesión y diagnosticar el tipo de error. Como resumen estadístico del comportamiento global, se reportan también la mediana y los valores máximo y mínimo de los IoU sobre las 51 imágenes del conjunto de datos.

C. Extracción de características

Entrando en la segunda fase del proyecto, a partir de la región segmentada se extrae un vector de cinco características diseñado para cubrir las dimensiones más informativas de la regla clínica ABCDE junto con una medida de textura:

- **Asimetría (A):** se recorta la máscara de la lesión a su *bounding box* y se solapa con su reflejo horizontal. El grado de asimetría se calcula como la proporción del área no superpuesta respecto a la unión de ambas formas ($1 - IoU$). Valores cercanos a 0 indican simetría total, y cercanos a 1, asimetría severa.
- **Circularidad (B):** mide la irregularidad del borde a partir del área y el perímetro del contorno mediante la expresión $C = 4\pi A/(P^2 + \varepsilon)$, donde el término $\varepsilon = 10^{-7}$ evita la división por cero en máscaras degeneradas. Toma el valor 1 para un círculo perfecto y decrece para formas irregulares, signo asociado a melanomas.
- **Color (C):** se calculan la media y la desviación típica del canal rojo sobre los píxeles de la lesión. La media captura la tonalidad general de la lesión, permitiendo al modelo detectar si el tejido es inusualmente oscuro o claro frente a un lunar estándar. Por su parte, la desviación típica mide la variabilidad cromática. Así, un valor bajo indica un color uniforme (propio de lunares benignos), mientras que un valor alto refleja una heterogeneidad cromática, característica frecuente en melanomas.
- **Textura (GLCM):** se construye la matriz de co-ocurrencia de niveles de gris (GLCM) sobre la región de la lesión recortada a su *bounding box*, enmascarando a cero los píxeles de fondo para no alterar la estadística. De ella se extrae el descriptor de *contraste*, que cuantifica la variación local de intensidad y refleja la rugosidad interna de la lesión. Aunque la textura no forma parte de la regla ABCDE original, se ha incluido como descriptor complementario por su capacidad para capturar patrones internos heterogéneos, frecuentes en lesiones malignas.

El proceso de selección de características fue iterativo. Inicialmente se exploraron descriptores morfológicos adicionales (área, solidez, diámetro), estadísticos de los canales verde y azul, métricas de textura secundarias (homogeneidad y energía GLCM), filtros de Gabor y patrones binarios locales (LBP). Respecto al color, las métricas de los canales verde y azul se excluyeron por su alta colinealidad con el rojo. El resto de descriptores se descartaron al comprobar que no mejoraban el porcentaje de acierto del clasificador. Esta reducción a un conjunto final de cinco variables previene el sobreajuste asociado a la alta dimensionalidad en conjuntos de datos reducidos. Por último, para confirmar la independencia entre los descriptores seleccionados, se calculó una matriz de correlación de Pearson sobre el conjunto final: la correlación máxima absoluta observada fue $|r| = 0,54$, muy por debajo del umbral habitual de redundancia ($|r| > 0,8$).

D. Modelo de Clasificación

Primero se realizó una comparativa entre los algoritmos de clasificación (*K-Nearest Neighbors*, *Random Trees* y *Support Vector Machine*). Tras verificar que todas las arquitecturas ofrecían una capacidad de detección clínica equivalente, se seleccionó la *Support Vector Machine* (SVM) por su mayor robustez y estabilidad matemática. Dentro de esta arquitectura, se compararon empíricamente los kernels lineal y gaussiano (RBF), seleccionándose finalmente el kernel lineal. La razón fue que, por un lado, proporcionó un mejor rendimiento en validación cruzada, lo que indica que las clases son aproximadamente separables de forma lineal en el espacio de cinco características y, además, es un modelo más simple y, por tanto, menos propenso al sobreajuste, lo cual resulta

especialmente adecuado dado el reducido tamaño del conjunto de datos.

Dado que las cinco características presentan rangos de magnitud muy dispares (por ejemplo, la circularidad varía entre 0 y 1, mientras que el contraste GLCM alcanza valores de varios cientos), fue necesario normalizarlas antes del entrenamiento. De lo contrario, las variables de mayor magnitud dominarían el cálculo de distancias de la SVM, sesgando el modelo. Para ello se empleó *StandardScaler*, ajustándolo únicamente sobre el conjunto de entrenamiento de cada iteración y aplicándolo después al conjunto de test. Esta práctica es esencial para evitar fugas de información del conjunto de test hacia el de entrenamiento.

El único hiperparámetro del modelo, el parámetro de regularización C , se optimiza automáticamente mediante el método `trainAuto` de OpenCV, que realiza una búsqueda en *grid* con validación cruzada interna sobre el conjunto de entrenamiento de cada iteración. Esta opción se prefirió frente a la fijación manual del hiperparámetro porque permite adaptar el modelo a cada partición sin introducir sesgo del experimentador y proporcionó mejor rendimiento que el valor por defecto $C = 1$.

E. Validación Cruzada Leave-One-Out

Debido al tamaño reducido del dataset ($N=51$), se ha seleccionado la validación cruzada *Leave-One-Out* (LOOCV) frente a la alternativa clásica de k -fold. La partición mediante k -fold, por ejemplo con $k = 10$, resultaría en conjuntos de test excesivamente pequeños (aprox. 5 imágenes), lo que introduciría una alta varianza en la estimación del rendimiento y una dependencia significativa del particionado aleatorio. Por el contrario, LOOCV, al configurar el caso límite $k=N$, maximiza el conjunto de entrenamiento en cada iteración (50 imágenes), proporcionando una estimación más estable. Además, al ser un método determinista, no depende de cómo se mezclen aleatoriamente los datos, lo que garantiza la reproducibilidad de los resultados.

III. RESULTADOS

En esta sección se evalúan los resultados obtenidos en las dos fases del proyecto.

A. Evaluación de la Fase 1: Segmentación

El algoritmo de segmentación se evaluó comparando las 51 máscaras generadas frente al *Ground Truth* mediante la métrica IoU (Eq. 1). Los resultados globales obtenidos fueron:

- **IoU medio (mIoU):** 82,83%
- **IoU mediano:** 82,70%
- **IoU máximo:** 97,17% (ISIC_0000354)
- **IoU mínimo:** 52,11% (ISIC_0000515)

Estos valores confirman una calidad de segmentación notable. El análisis cualitativo muestra que los falsos negativos (píxeles de la lesión omitidos) predominan sobre los falsos positivos (píxeles de piel sana incluidos por error), indicando que el sistema tiende a infraestimar ligeramente la extensión de la lesión, descartando los bordes más difusos donde la

transición de color hacia la piel es más tenue. Asimismo, es preciso señalar que algunas de las máscaras manuales presentan menor precisión y detalle visual que las generadas por el algoritmo automático, lo cual condiciona el cálculo del IoU y la distribución de los errores. No obstante, el IoU medio obtenido garantiza la robustez necesaria para la etapa posterior de clasificación, consolidando la segmentación como una base sólida para el correcto funcionamiento del modelo predictivo.

B. Evaluación de la Fase 2: Clasificación

Para evaluar la redundancia entre los descriptores extraídos (Asimetría, Circularidad, Media y Desviación típica del canal rojo y Contraste), se ha calculado la matriz de correlación de Pearson, presentada en la Tabla I. Se observa una ausencia de colinealidad significativa (no existen valores cercanos a ± 1), lo que confirma que cada descriptor aporta información complementaria y no redundante. Esto valida la selección del conjunto de cinco características, asegurando un espacio de representación eficiente para el clasificador SVM.

TABLE I
MATRIZ DE CORRELACIÓN DE PEARSON.

	Asim.	Circ.	Media R	Desv. R	Cont.
Asimetría	1.00	-0.44	-0.24	0.31	-0.13
Circularidad	-0.44	1.00	0.19	-0.18	0.24
Media R	-0.24	0.19	1.00	-0.50	0.54
Desv. R	0.31	-0.18	-0.50	1.00	0.02
Contraste	-0.13	0.24	0.54	0.02	1.00

Tras verificar la idoneidad de los descriptores, la capacidad diagnóstica del sistema se evaluó mediante validación cruzada LOOCV. El clasificador SVM alcanzó un porcentaje de acierto global (*accuracy*) del **90,20%** (46 aciertos sobre 51 imágenes). La matriz de confusión resultante se presenta en la Tabla II.

TABLE II
MATRIZ DE CONFUSIÓN.

Clase Real	Pred. Benigno	Pred. Melanoma
Benigno (32)	30 (TN)	2 (FP)
Melanoma (19)	3 (FN)	16 (TP)

Cabe destacar que el conjunto de datos presenta un desequilibrio de clases (32 muestras benignas frente a 19 melanomas). Esta distribución justifica la priorización de métricas como la sensibilidad y la especificidad sobre el *accuracy* global. Por lo tanto, a partir de matriz de confusión se calcularon estas métricas clínicamente relevantes para un problema de detección de patología:

- **Sensibilidad:** 84,21% (16/19 melanomas detectados).
- **Especificidad:** 93,75% (30/32 lunares benignos correctamente clasificados).

La alta especificidad demuestra que el modelo es sumamente fiable para confirmar la ausencia de patología. Identifica de forma correcta casi todos los tejidos sanos, lo que se traduce en una tasa muy baja de falsas alarmas (solo dos falsos positivos: ISIC_0000327 e ISIC_0000377).

Por su parte, la sensibilidad, que evalúa la capacidad de detectar la enfermedad real, es ligeramente inferior. El sistema omite tres melanomas (ISIC_0000160, ISIC_0010034 e ISIC_0010597), clasificándolos erróneamente como benignos. En el ámbito del diagnóstico médico, esta métrica es la más crítica ya que un falso negativo implica clasificar como sano un tejido maligno, lo que retrasa la intervención médica en una patología donde la detección temprana es esencial.

El análisis visual de las imágenes correspondientes a los falsos negativos sugiere que estas lesiones presentan tonalidades y texturas muy similares a las de los lunares sanos, lo que limita la capacidad de discriminación de los descriptores extraídos. Por el contrario, los falsos positivos ocurren en lesiones benignas con bordes marcadamente irregulares, lo que penaliza la métrica de circularidad y provoca que el algoritmo las clasifique como sospechosas.

IV. CONCLUSIONES Y POSIBLES MEJORAS

En este trabajo se ha desarrollado una metodología totalmente automática para la detección de melanomas a partir de imágenes dermatoscópicas, integrando técnicas de visión artificial y aprendizaje supervisado. El sistema ha demostrado una eficacia notable, con un IoU medio del 82,83% en segmentación y un acierto del 90,20% en clasificación (sensibilidad 84,21%, especificidad 93,75%).

La combinación de descriptores que cubren las dimensiones A, B y C de la regla clínica ABCDE junto con una medida de textura ha resultado efectiva pese al reducido tamaño del conjunto de datos. El pre-procesado morfológico mediante *black-hat* e *inpainting* fue determinante para garantizar segmentaciones fiables en presencia de vello y otros artefactos.

No obstante, la segmentación no fue perfecta en todos los casos. En algunas lesiones el algoritmo no logró delimitar el contorno con exactitud, recortando en la mayoría de los casos parte de la lesión. Estos errores se concentraron en lesiones con bordes difusos o con poco contraste respecto a la piel, donde la umbralización de Otsu no consigue una separación nítida, y repercuten directamente en la posterior extracción de características.

Como posibles líneas de mejora se proponen:

- **Mejora de la segmentación:** incorporar técnicas más robustas frente a lesiones de bajo contraste o bordes difusos.
- **Reducción de los falsos negativos:** estudiar la inclusión de nuevos descriptores morfológicos y cromáticos que permitan discriminar con mayor precisión aquellos melanomas que presentan una alta similitud visual con el tejido sano.
- **Tratamiento del desbalanceo:** explorar técnicas de balanceo de clases para mejorar la sensibilidad sobre la clase minoritaria (melanomas).
- **Ampliación del dataset:** un mayor número de imágenes permitiría incorporar descriptores adicionales sin riesgo de sobreajuste y mejorar la representatividad estadística del modelo.

- **Aprendizaje profundo:** explorar el uso de Redes Neuronales Convolucionales (CNN) para la extracción automática de características, comparando su rendimiento con el enfoque clásico aquí presentado.

REFERENCES

- [1] American Cancer Society, "Survival Rates for Melanoma Skin Cancer," Ene. 2026. [Online]. Disponible en: <https://www.cancer.org/cancer/types/melanoma-skin-cancer/detection-diagnosis-staging/survival-rates-for-melanoma-skin-cancer-by-stage.html>
- [2] M. E. Celebi *et al.*, "A methodological approach to the classification of dermoscopy images," *Computerized Medical Imaging and Graphics*, vol. 31, no. 6, pp. 362–373, 2007.